Сжатие благоприятствует согласованности, а не истине: когда и почему языковые модели предпочитают корректные продолжения

Автор: Константин Крестников
Дата: 03.2026

Аннотация

Почему языковые модели иногда предпочитают корректные утверждения, даже если обучаются на корпусах смешанного качества? В работе этот вопрос исследуется на контролируемых синтетических корпусах. Рассматривается принцип `compression--consistency`: градиентное обучение благоприятствует гипотезам, которые дают более короткое и более внутренне согласованное описание обучающих данных. В такой формулировке bias в сторону истины не является фундаментальным свойством. Он возникает в тех условиях, где ложные альтернативы сжимаются хуже, чем корректная система правил. Модели сжимают текст, а не внешнюю реальность; поэтому наблюдаемый эффект следует интерпретировать как свойство структуры корпуса при конкретной процедуре обучения.

Эта гипотеза проверяется на GPT-2-подобных char-level трансформерах размером от 3.5M до 86M параметров, обученных на синтетических математических корпусах с контролируемыми смесями корректных и некорректных решений. При случайных ошибках парная оценка показывает выраженное предпочтение корректных завершений: 83.1% accuracy при `50/50` и 66.7% даже при `10/90`. В синтетическом естественно-языковом мире тот же знак эффекта сохраняется, но его величина ниже (57.7%). Замена случайных ошибок на внутренне согласованную, но математически ложную систему правил убирает этот эффект в выпущенных fixed-step запусках: paired accuracy для coherent условий остаётся около уровня случайного выбора на всех размерах (`47.2%--52.6%`).

Дополнительные эксперименты очерчивают границы эффекта. Включение шага верификации в задачи с когерентной ложной системой восстанавливает предпочтение корректных завершений на tiny-модели (70.9%), хотя тренд по размеру в этой части остаётся предварительным из-за fixed-step обучения и ограниченной репликации на больших размерах. Пересборка multi-rule эксперимента на matched paired evaluation показывает ступенчатый, но не одномоментный рост: от 46.6% при `N=1` до 88.3% при `N=10`. Главный вывод поэтому формулируется узко: в контролируемых синтетических корпусах предпочтение

модели к корректным решениям лучше согласуется со сжимаемостью и внутренней согласованностью конкурирующих альтернатив, чем с истиной в абстрактном смысле.

---

1. Введение

Языковые модели демонстрируют всё более высокие результаты на фактуальных бенчмарках, однако продолжают уверенно порождать ложные утверждения. Отсюда возникает вопрос: при каких условиях сама цель next-token prediction создаёт preference в пользу корректных продолжений?

Существующие объяснения акцентируют разные механизмы. Рост масштаба моделей повышает фактуальную точность (Kadavath et al., 2022). RLHF и близкие процедуры смещают генерацию в сторону человечески предпочтительных ответов. Статистика корпуса также влияет на поведение модели: частота фактов и структура источников соотносятся с вероятностью корректного ответа (Elazar et al., 2022; Joshi et al., 2024; Kandpal et al., 2023). В активациях моделей были обнаружены представления, коррелирующие с truthfulness (Burns et al., 2023; Marks & Tegmark, 2023). Однако эти объяснения не отвечают прямо на более базовый вопрос: почему сама языковая модель, обучаемая только на предсказании следующего токена, вообще должна предпочитать истину?

В работе предполагается, что ответ связан со сжатием. Минимизация cross-entropy эквивалентна минимизации длины кода (Shannon, 1948; Deletang et al., 2024), что связывает обучение языковых моделей с Minimum Description Length (Rissanen, 1978; Grünwald, 2007). Модель, лучше предсказывающая токены, является лучшим компрессором. Однако сжатие не благоприятствует истине само по себе: оно благоприятствует наиболее сжимаемой гипотезе, совместимой с данными. В этом смысле корректная система получает преимущество только тогда, когда ложные альтернативы структурно менее регулярны или требуют большего числа исключений.

Эта рамка имеет три ограничения. Во-первых, модели сжимают текст, а не внешний мир: под «истиной» здесь понимается корректность математических выводов в синтетических корпусах. Во-вторых, частота может перевесить структурное преимущество. В-третьих, разрыв в сжимаемости между истиной и ложью зависит от устройства корпуса, а не является универсальным. Дальнейший анализ ограничен synthetic corpora и fixed-step training; size-сравнения не следует читать как compute-matched scaling laws.

2. Связь с литературой

Связь между предсказанием и сжатием восходит к классическим результатам теории информации. Shannon (1948) показал, что оптимальное сжатие требует знания истинного распределения данных. Solomonoff (1964) связал предсказание с длиной программы гипотезы. MDL-подход (Rissanen, 1978; Grünwald, 2007) формализует выбор модели как задачу минимизации суммарной длины описания модели и данных при условии модели.

Для языковых моделей эта линия была эмпирически усилена работой Deletang et al. (2024), где показано, что LM можно рассматривать как универсальный компрессор. Huang et al. (2024) обнаружили почти линейную связь между качеством сжатия и downstream capability. Wan & Mei (2025) формализовали связь между обучением LLM и Solomonoff induction. Эти работы мотивируют вопрос не о том, связано ли обучение LM со сжатием, а о том, в каких условиях это сжатие будет согласовано с корректностью продолжений.

Отдельная линия исследований посвящена truthfulness как внутреннему свойству представлений. Burns et al. (2023) и Marks & Tegmark (2023) показали, что в активациях возникают направления, связанные с истинностью утверждений. В представленной работе вместо репрезентационного анализа изучается поведенческий уровень: когда compression pressure порождает paired preference за корректное продолжение, а когда этот эффект исчезает.

3. Методология

3.1 Модели и обучение

Используется GPT-2-подобный decoder-only transformer, реализованный в MLX. Конфигурации:

Конфигурация	Слои	`d_model`	Heads	Параметры
`tiny`	4	256	4	3.5M
`small`	6	384	6	11M
`medium`	8	512	8	26M
`large`	12	768	12	86M

Во всех основных запусках используется AdamW, `lr=3e-4`, cosine decay с warmup, `seq_len=256`, `batch_size=32`, `5000` шагов обучения. Experiments 1–3 выполняются на `tiny`. В scaling-части random `50/50` и coherent `50/50` теперь выпущены с четырьмя seed-ами на каждом размере. Эти сравнения интерпретируются как fixed-step результаты, а не как compute-matched scaling laws.

Четыре seed-а достаточны, чтобы проверить устойчивость знака эффекта, но недостаточны для точной оценки between-run uncertainty. Поэтому в работе seed-level effect sizes используются как основной уровень анализа variability по обучению, а парные статистики внутри одного run рассматриваются отдельно.

3.2 Генерация корпусов

Генератор создаёт математические задачи четырёх типов: arithmetic, algebraic factorization, equation solving и differentiation. Каждая задача представлена пошаговым решением на английском языке и проверяется через SymPy. Используется char-level tokenizer, чтобы исключить артефакты BPE как дополнительный фактор.

Сравниваются три базовых типа ошибок:

- `random`: одна правдоподобная ошибка в случайном месте решения; ошибки по существу уникальны;
- `coherent`: одна систематическая ложная rule-system для каждого типа задач;
- `contradictory`: простые правила, нарушающие базовую алгебраическую структуру.

3.3 Метрики

Парная оценка (`paired evaluation`) — основная метрика. Для каждой задачи строится общий prompt и два completion-а: correct и incorrect. Negative log-likelihood считается только по completion tokens при одинаковом prompt. Это устраняет смешение, возникающее при сравнении разных промптов. Основные метрики: `pair accuracy`, средний `ΔLoss` по completion tokens и signed-rank test Wilcoxon.

Для центральных математических условий дополнительно сохраняются две auxiliary paired-метрики: `sum_nll` по completion tokens и `length_matched_mean_nll`, где усреднение берётся только по общей минимальной длине completion-а в паре. В ключевых сравнениях (`random 50/50`, `random 10/90`, `coherent 50/50`) эти варианты сохраняют тот же знак, поэтому основной paired-метрикой остаётся средний NLL по completion tokens.

Генератор paired test sets стремится создать `5000` задач, но часть случаев отбрасывается, если после common-prefix extraction корректное и некорректное продолжения оказываются одинаковыми. Поэтому в итоговых JSON-артефактах число пар может быть меньше `5000`; для random math benchmark это `4951`.

Корпусная оценка (`corpus-level evaluation`) — вторичный диагностический индикатор. В revision используются две версии:

1. legacy-оценка по случайным окнам из конкатенированного токенизированного потока correct и incorrect corpora;
2. deterministic example-block evaluation, где каждое held-out решение оценивается отдельно, без переходов через границы примеров.

В обоих случаях используется соглашение:

```
ΔLoss = Loss(incorrect) − Loss(correct).
```

Положительное значение означает меньший loss на корректных примерах. Эти метрики интерпретируются как диагностические, а не как основной тест на truth bias.

3.4 Статистика

Для paired evaluation в коде используется **односторонний** Wilcoxon (`alternative='greater'`). Это проверяет гипотезу о том, что `NLL(incorrect) − NLL(correct)` положителен внутри одного обученного run. Такая p-value характеризует uncertainty по held-out pairs внутри модели, но не устойчивость всей training procedure.

Отдельно от этого для seed-level directions используется двусторонний binomial test. Таким образом, разделяются два уровня неопределённости:

- uncertainty over test pairs within one model;

- variability across independently trained runs.

3.5 Эвристическая MDL-рамка

Теоретическая интерпретация в работе носит эвристический характер. Рассматриваются две конкурирующие системы правил: корректная `T1` и альтернативная `T2`. Если `T2` требует множества несвязанных исключений, её эффективная длина описания растёт вместе с корпусом. Если же `T2` является компактной, но ложной coherent-system, компрессор не получает явного преимущества в пользу истины. Эта рамка согласуется с экспериментами, но не формулируется как теорема о конечных SGD-trained transformers.

3.6 Условия экспериментов

- **Experiment 1:** random errors на пяти пропорциях `50/50`–`10/90`, плюс coherent и contradictory controls.
- **Experiment 2:** coherent errors с наблюдениями (`observed`) при разных observation ratios.
- **Experiment 3:** условия A–E для разных типов ложных теорий и объяснений.
- **Experiment 4:** scaling по размеру модели; для random и coherent `50/50` теперь доступны полные public artifacts на всех размерах, но их следует интерпретировать как fixed-step comparison.
- **Experiment 5:** multi-rule errors, пересобранные на matched paired evaluation.
- **Experiment 9:** chained tasks с верификацией.

4. Experiment 1: Random, Coherent и Contradictory Errors

4.1 Random errors

Legacy corpus-level table для mixed setting:

Пропорция	Loss correct	Loss incorrect	`ΔLoss`	Seeds -> correct
`100/0`	0.1313	0.2028	+0.0715	1/1
`50/50`	0.1384	0.1499	+0.0115	4/4
`40/60`	0.1403	0.1492	+0.0089	4/4
`30/70`	0.1422	0.1486	+0.0064	4/4
`20/80`	0.1455	0.1487	+0.0033	4/4
`10/90`	0.1503	0.1487	-0.0016	0/4

На уровне legacy corpus metric наблюдается монотонное уменьшение `ΔLoss` с инверсией знака при `10/90`. Однако paired evaluation показывает более устойчивую картину:

Пропорция	Avg `ΔLoss` (paired)	Pair accuracy
`50/50`	+0.0480	83.1%

Пропорция	Avg `ΔLoss` (paired)	Pair accuracy
`40/60`	+0.0434	79.0%
`30/70`	+0.0356	74.7%
`20/80`	+0.0285	69.3%
`10/90`	+0.0169	66.7%

Следовательно, при сильном дисбалансе структурное преимущество корректных решений сохраняется на уровне matched prompts, хотя диагностическая корпусная метрика может менять знак.

4.2 Deterministic full-test robustness check

Для ключевых условий был добавлен deterministic example-level eval по полному held-out set:

Условие	Loss correct	Loss incorrect	`ΔLoss`	Seeds -> correct
`mixed 50/50`	0.1089 +/- 0.0011	0.1246 +/- 0.0007	+0.0157 +/- 0.0004	4/4
`mixed 10/90`	0.1208 +/- 0.0004	0.1233 +/- 0.0002	+0.0025 +/- 0.0003	4/4
`coherent 50/50`	0.1086 +/- 0.0006	0.1077 +/- 0.0006	-0.0008 +/- 0.0003	0/4

Эта проверка снимает главный методологический упрёк к исходной версии `corpus-level` метрики. При random `10/90` знак больше не инвертируется, а coherent `50/50` остаётся отрицательным. Поэтому центральный вывод остаётся прежним: наиболее надёжная evidence-base исходит из paired evaluation, а корпусные метрики полезны как вторичный diagnostic layer.

4.3 Coherence spectrum

При `50/50` paired evaluation задаёт ясный спектр:

Тип ошибки	Pair accuracy	Avg `ΔLoss` (paired)
`random`	83.1% +/- 2.4%	+0.0480 +/- 0.0012
`contradictory`	49.0% +/- 1.2%	+0.0003 +/- 0.0006
`coherent`	47.2% +/- 2.8%	-0.0018 +/- 0.0006

Случайные ошибки дают сильный preference в пользу корректного completion-а. Contradictory errors практически гасят этот эффект. Coherent falsehood убирает его почти полностью. Этот контраст согласуется с идеей, что решающее значение имеет не truth value как таковой, а степень регулярности ложной альтернативы.

5. Experiments 2–3: Негативные результаты и расхождение метрик

Experiments 2–3 оказываются методологически важными именно потому, что в них `corpus-level DLoss` и paired metrics часто расходятся.

В `observed` и в условиях C/D/E corpus-level `ΔLoss` может оставаться положительным, тогда как paired accuracy удерживается около `49--50%`. Это указывает на то, что модель может хорошо сжимать форматированные discrepancy/correction patterns на уровне stream metric, не приобретая transferable preference в пользу correct completion при фиксированном prompt.

Следовательно, negative results здесь являются не побочным наблюдением, а ключевым выводом. Они показывают хрупкость corpus-level diagnostic при изменении длины, формата и локальной статистики текста.

6. Scaling, Multi-Rule и Chained Verification

6.1 Fixed-step scaling при random errors

Для random `50/50` paired accuracy растёт с размером модели в доступных fixed-step runs:

Размер	Pair accuracy	Avg `ΔLoss` (paired)
`tiny`	83.1%	+0.048
`small`	88.4%	+0.063
`medium`	88.4%	+0.067
`large`	89.1%	+0.070

Эта динамика не интерпретируется как scaling law. Более крупные модели могут быть недообучены при одинаковых `5000` шагах, а compute-matched comparison отсутствует.

6.2 Coherent scaling

Для coherent falsehood paired accuracy остаётся около уровня случайного выбора на всём диапазоне `3.5M–86M`: `47.2%` на tiny, `49.6%` на small, `52.6%` на medium и `51.4%` на large. Средний paired `ΔLoss` на всех размерах близок к нулю. Следовательно, в released fixed-step runs coherent-кривая остаётся практически плоской и не демонстрирует явного size-trend в пользу correct side.

6.3 Multi-rule experiment

После пересборки на matched paired evaluation наблюдается graded boundary case:

`N` rules	Pair accuracy	Avg `ΔLoss` (paired)
`1`	46.6%	-0.0019

N rules	Pair accuracy	Avg ΔLoss (paired)
2	77.6%	+0.0152
3	82.8%	+0.0213
5	84.8%	+0.0293
10	88.3%	+0.0440

Наиболее крупный рост происходит между N=1 и N=2, но данные лучше описываются как steep early rise с дальнейшим ростом, а не как немедленный phase transition.

6.4 Chained verification

В задачах с внутренней верификацией tiny-модель достигает 70.9% pair accuracy по сравнению примерно с 43% на coherent control. Это согласуется с гипотезой, что verification step делает ложную coherent-system менее предсказуемой. Size-trend в этой части остаётся предварительным: large покрыт только двумя seed-ами.

7. Обсуждение

Полученные результаты поддерживают более узкую картину, чем общая теория truthfulness.

Во-первых, compression pressure благоприятствует согласованности и предсказуемости структуры данных. В synthetic corpora truth получает преимущество только там, где ложные альтернативы менее сжимаемы.

Во-вторых, paired evaluation оказывается методологически предпочтительнее corpus-level DLoss. При 10/90, а также в ряде secondary conditions, corpus-level signal меняет знак или расходится с paired accuracy. Следовательно, исследования truth bias, основанные только на отдельных correct/incorrect corpora, могут переоценивать устойчивость эффекта.

В-третьих, coherent falsehood не является «шумом», который модель автоматически отфильтровывает. Если ложная система правил компактна и регулярна, она остаётся конкурентоспособной для компрессора.

В-четвёртых, включение verification step способно восстановить preference в пользу correct completions, но пока только в пределах sparse synthetic setup. Отсюда не следует общий вывод о real-world truthfulness.

8. Ограничения

Работа ограничена synthetic corpora, char-level tokenization и fixed-step training. Scaling-секция не является compute-matched. Conditions C/D/E различаются по длине и формату текста, что создаёт дополнительный confound для корпусных метрик. Pair-level p-values не заменяют between-run replication. В released artifact set для random и coherent 50/50 теперь доступны по четыре seed-а на каждом размере, тогда как для chained large остаются только два seed-а.

В synthetic-world appendix эффект заметно слабее, чем в математике. Поэтому перенос выводов на real-world factuality, hallucinations или benchmark truthfulness требует отдельных прямых экспериментов.

9. Заключение

В контролируемых синтетических корпусах preference модели определяется не истиной самой по себе, а тем, насколько сжимаемы и внутренне согласованы competing alternatives. Случайные ошибки создают преимущество для корректной rule-system; coherent falsehood это преимущество убирает. Multi-rule setting образует промежуточный случай, а verification может частично вернуть preference за корректные завершения.

Итоговая формулировка therefore должна оставаться ограниченной: представленные эксперименты согласуются с тем, что compression favors consistency rather than truth in the abstract. Для журнальной версии эта рамка является методологически более точной и лучше согласованной с кодом, артефактами и уровнем реально показанных данных.

Приложение: воспроизводимость

Код, артефакты и manifests синхронизированы следующим образом:

- `training/eval_perplexity.py` различает legacy random-window eval и deterministic example-block eval;
- `scripts/collect_results.py` служит единым агрегатором таблиц;
- `results_manifest.md` фиксирует, какие claims supported публичными артефактами;
- `claims_manifest.md` различает safe, qualified и legacy claims;
- `data/eval_inputs_manifest.md` документирует evaluation inputs и их checksums.